动植物重测序分析项目结题报告

北京格致博雅生物科技有限公司

项目信息

项目名称 XXXXXX

项目编号 SA2024XXXX

物种名称 XXX

样本数量 XX 个

报告时间 2024 年 5 月 15 日

目录

1. 背景介绍 4
2. 生物信息分析 4
2.1 测序数据质控 4
2.2 测序数据质量评估 5
2.2.1 测序质量分布 5
2.2.2 测序错误率分布 6
2.2.3 测序数据评估结论 6
2.3 参考基因组比对 7
2.4 SNP 检测 8
2.5 SNP 结果注释 8
2.6 InDel 注释结果 10
3. 生物信息分析软件列表 11
4. 参考文献 11
5. 关于格致博雅 12
5.1 公司简介 12
5.2 联系我们 12

1. 背景介绍

变异检测是一种生物信息学方法，主要是通过高通量测序技术对某一物种个体或群体的基因组 DNA 进行测序，并对比参考基因组，以识别和分析序列中的遗传变异。这些变异包括但不限于单核苷酸多态性（SNPs）、插入缺失（InDels）、结构变异（SVs）、以及拷贝数变异（CNVs）。变异检测的目的是获取大量遗传变异信息，进而用于进化关系研究、功能基因挖掘、疾病关联分析、遗传标记开发等领域。

全基因组重测序变异检测已经成为动植物分子育种最为快速有效的方法之一，利用华大 DNBSEQ-T7 测序平台，大大提升了大数据大样本的检测分析服务能力，赋予了科研人员获取大量精确基因组数据的能力，更准确地挑选出具有优良性状的基因，从而优化改良作物和动物的品种，显著提升产量、品质以及环境适应性。

2. 生物信息分析

2.1 测序数据质控

DNBSEQ-T7 平台执行高通量测序生成的初始图像数据，测序质量评估发生在 Base Calling 阶段，旨在确定每个碱基识别的错误概率，以此作为评判测序精确度的标准。Base Calling 是指将测序仪产生的原始信号转换为具体的碱基（A、T、C、G）的过程。这一过程的准确性直接影响到后续数据分析的可靠性。测序质量得分是对每个碱基测序正确性的量化评估，通常采用 Phred 分数表示，其形式上是一个与错误概率相关的对数转换值。

Phred 分数计算公式为：Phred Score = -10 * log10(错误概率)。

Phred 分数为 30 的碱基，其错误概率为 10^(-3)，即该碱基被正确识别的概率为 99.9%。

表 2.1 下机数据质量

测序错误率	测序质量值
5%	13
1%	20
0.10%	30
0.01%	40

将测序得到的原始图像数据经 Base Calling 转化为序列数据，我们称之为 raw data 或 raw reads，结果以 fastq 文件格式存储（文件名：*.fq）。然而原始测序数据中会包含接头信息，低质量碱基，未测出的碱基（以 N 表示），这些信息会对后续的信息分析造成很大的干扰，分析前需将这些干扰信息去除掉，最终得到的数据即为有效数据，我们称之为 clean data 或 clean reads。原始数据过滤方法如下：

1）需要过滤掉含有接头序列的 reads；

2）当单端测序 read 中 N 的含量超过该条 read 长度比例的 10% 时，需要去除此对 paired reads；

3）当单端测序 read 中含有的低质量（<=5）碱基数超过该条 read 长度比例的 50% 时，需要去除此对 paired reads。

经过对测序数据的严格过滤，得到高质量的 clean data。对检测样本产出数据进行统计（表 2.2），包括测序数据产量，测序错误率，Q20 含量，Q30 含量，GC 含量等。

表 2.2 测序数据质控结果

Sample	Raw Base(G)	Clean Base(G)	Effective Rate(%)	Error Rate(%)	Q20(%)	Q30(%)	GC Content(%)
Y7	26.39	26.16	99.17	0.03	97.75	93.75	43.59
R8	27.5	27.26	99.13	0.03	97.81	93.97	46.1
Y1	31.06	30.75	99.02	0.03	97.6	93.31	43.48
Y5	29.38	29.1	99.07	0.03	97.69	93.59	43.47
Y11	27.46	27.19	99.04	0.03	97.84	93.94	43.63

2.2 测序数据质量评估

2.2.1 测序质量分布

测序数据的质量（图 2.1）主要会分布在 Q30 以上（即正确识别率 99.9 % 以上），这样才能保证后续高级分析的正常进行。据测序技术的特点，测序片段末端的碱基质量一般会比前端的低。

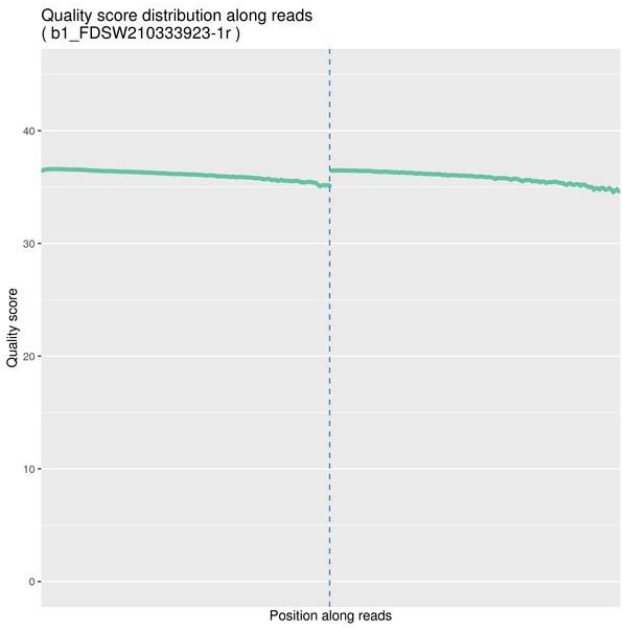

图 2.1 测序质量分布图

2.2.2 测序错误率分布

测序错误率（图 2.2）与碱基质量有关，根据测序技术的特点，测序片段末端的错误率会偏高，并且大片段文库测序的错误率比小片段文库测序的错误率高。（其他样本请见 QC 质控中 2.2 节）

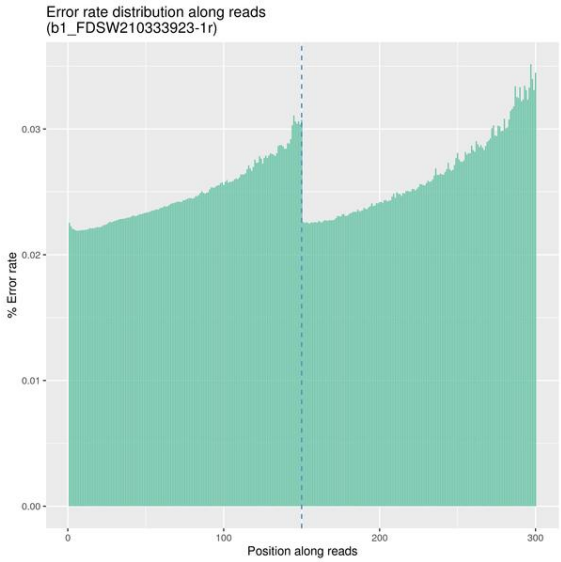

图 2.2 测序错误率分布图

2.2.3 测序数据评估结论

本批总共测序 70 个样本，高质量数据量为 1976.44 Gb，测序质量较高（平均 Q20 97.11%、平均 Q30 92.36%），其中

单个样本最低 Raw data 产出为 23.94 G，最高 Raw data 产出为 35.45 G，

单个样本最低 Effective rate (%) 为 98.49，最高为 99.31，

单个样本最低 Q20 (%) 为 95.62，最高为 97.97，

单个样本最低 Q30 (%) 为 89.16，最高为 94.4，

单个样本最低 GC 含量 (%) 为 42.88，最高为 47.97，

GC 分布正常，70 个样本都没有被污染，此次建库测序成功。

2.3 参考基因组比对

有效的高质量测序数据（clean data）通过 BWA 软件比对到参考基因组，比对结果经 SAMTOOLS 去除重复。样本比对率反映了样本测序数据与参考基因组的相似性，覆盖深度和覆盖度能够直接反映测序数据的均一性及与参考序列的同源性。各个样本的比对结果显示，它们与参考基因组的相似度达到重测序分析的要求。

表 2.3 测序数据比对质量结果

Sample	Total reads	Mapped reads	Mapping rate	Average depth	Coverage 1X	Coverage 10X	Coverage 20X
LKY01	178360200	177536219	97.63%	10.39	82.09%	24.03%	1.67%
LKY02	173200336	171999072	97.63%	10.1	83.14%	27.49%	2.19%
LKY03	171190846	169882629	97.09%	9.92	81.78%	20.63%	1.31%
LKY04	176030494	174825457	97.58%	10.26	86.71%	28.05%	1.73%
LKY05	184074086	183092216	97.63%	10.73	82.88%	27.42%	2.04%
LKY06	213592768	212113701	97.33%	12.42	83.37%	36.02%	3.11%

注：

Sample: 样本名。

Total reads：有效测序数据的 reads 总条数。

Mapped reads：比对到 reference 上的 reads 条数（包括单端比对和双端比对）。

Mapping rate：比对率，比对到参考基因组上的 reads 数目除以有效测序数据的 reads 数目。

Average depth：平均测序深度，比对到参考基因组的碱基总数除以基因组大小。

Coverage 1X：参考基因组中至少有 1 个碱基覆盖的位点占基因组的百分比。

Coverage 10X：参考基因组至少有 10 个碱基覆盖的位点占基因组的百分比。

Coverage 20X：参考基因组至少有 20 个碱基覆盖的位点占基因组的百分比。

2.4 SNP 检测

SNP（单核苷酸多态性）主要是指在基因组水平上由单个核苷酸的变异所引起的 DNA 序列多态性，包括单个碱基的转换、颠换等。我们采用 GATK HaplotypeCaller 模块对 bam 文件进行检测，获得每个样本的 GVCF，然后利用 CombineGVCFs 将所有样品的 GVCF 合并成一个文件，再利用 GenotypeGVCFs 对合并后的变异文件进行分型，最后从分型文件得到所有 SNP 变异位点。

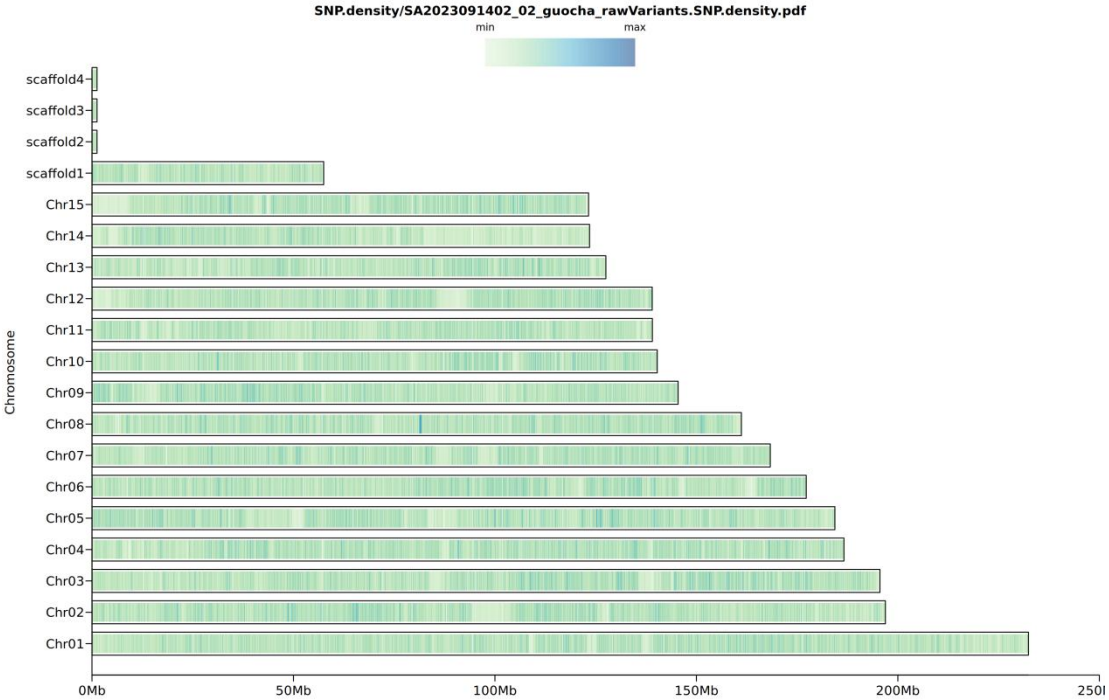

图 2.4. SNP 变异密度分布图

注：横坐标表示基因组位置，纵坐标表示染色体编号。

2.5 SNP 结果注释

ANNOVAR 是一款高度效能的软件，专门设计来快速精准地解析基因组数据中的变异意义。它依托最新的生物信息学知识，对来自多种基因组筛查的遗传变异进行详尽的功能注解。只需提供变异位点的染色体位置（起始与终止）、参考核苷酸及其变化形式，ANNOVAR 即能执行 Gene-based annotation、Region-based annotations、Filter-based annotation 和 Other functionalities。因其卓越的注释能力和在国际研究领域的广泛认可，我们选择 ANNOVAR 来深度解读 SNP 检测的科学输出，确保研究结果的全面性和可靠性。

表 2.5 SNP 检测结果统计

	Category	Number of SNPs
	Upstream	93,281
Exonic	Stop gain	734
Exonic	Stop loss	188
Exonic	Synonymous	68,110
Exonic	Non-synonymous	82,379
	Intronic	8,123,336
	Splicing	4227
	Downstream	125,137
	upstream/downstream	2550
	Intergenic	13,414,800
	Other	218,465
	ts	14,501,815
	tv	7,631,392
	ts/tv	1.9
	Total	22,133,207

全基因组中的单核苷酸多态性（SNP）变异能够被分类为 6 种类型。以 T:A 转换为 C:G 的情况为例，这一类型的 SNP 变异涵盖了 T 转变为 C 以及 A 转变为 G 两种情况。考虑到测序数据既可以与参考基因组的正链相对照，也可以与负链匹配，如果在参考基因组的正链上观察到 T 转换为 C 的变异，则相应地，在负链的同一位置上就会出现 A 转换为 G 的变异，因此我们将 T>C 与 A>G 视为同一类变异。下面的图展示了 SNP 变异的频谱分布。

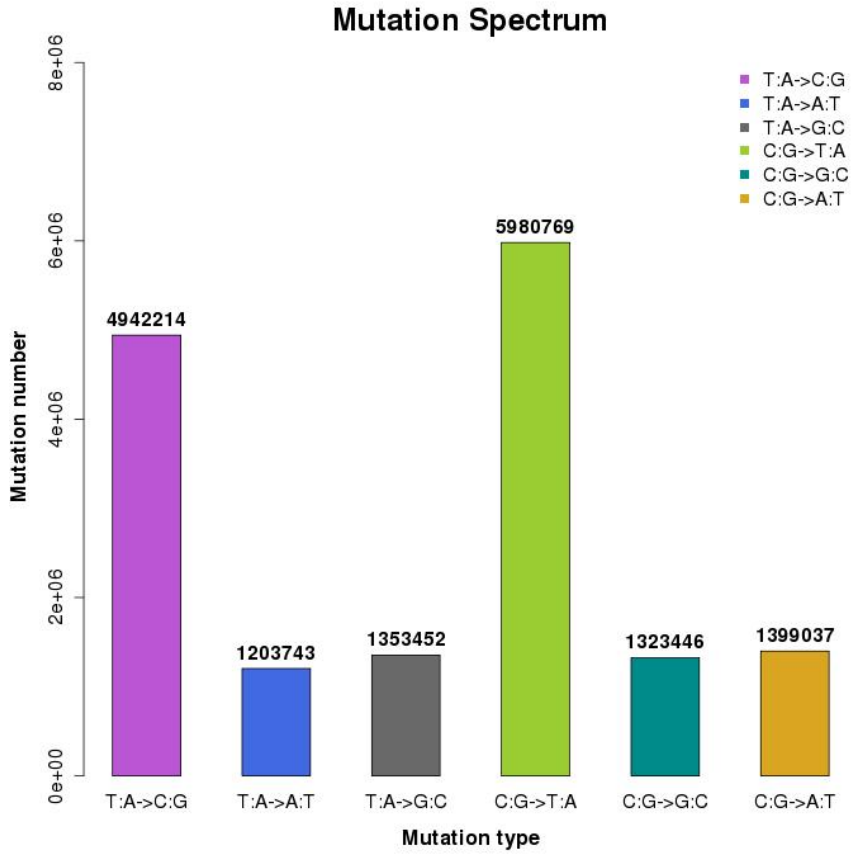

图 4.不同类型分布图

注：横坐标表示 6 种不同的变异类型，纵坐标表示变异数量。

2.6 InDel 注释结果

InDel（Insertion and deletion）是指长度小于 50 bp 的插入和缺失片段。变异发生在编码区域或剪接位点，可能会直接影响蛋白质的氨基酸序列。移码变异因涉及的碱基数为 3 的非整数倍，能引起阅读框架的偏移，从而对基因功能产生显著影响，同时受到更大的筛选压力。为精确检测 InDel 变异，我们采用 GATK 工具进行检测；随后，借助 ANNOVAR 软件，根据数据库信息，对 InDel 位点进行注释，注释内容涵盖变异的位置信息、类型等。具体的注释内容基本同 SNP 注释。

3. 生物信息分析软件列表

软件	版本	说明
BWA	0.7.17-r1188	将 NGS 测序数据比对到参考基因组
SAMTOOLS	1.19	对 SAM 比对结果进行排序、合并，建立索引等操作
GATK	4.4.0.0	重测序变异检测
Annovar	v2.2.25	对 SNP、Indel 进行注释

4. 参考文献

1. Li H, Durbin R: Fast and accurate short read alignment with Burrows-Wheeler transform. Bioinformatics 2009, 25(14):1754-1760.
2. Li, H. Aligning sequence reads, clone sequences and assembly contigs with BWA-MEM. ArXiv 1303(2013).
3. Li H, Handsaker B, Wysoker A, Fennell T, Ruan J, Homer N, Marth G, Abecasis G, Durbin R: The Sequence Alignment/Map format and SAMtools. Bioinformatics 2009, 25(16):2078-2079
4. McKenna, A. et al. The Genome Analysis Toolkit: a MapReduce framework for analyzing next-generation DNA sequencing data. Genome Res 20, 1297-303 (2010).
5. Li, H. A statistical framework for SNP calling, mutation discovery, association mapping and population genetical parameter estimation from sequencing data. Bioinformatics 27, 2987-93 (2011).
6. Auwera, Geraldine A Van Der , et al. From FastQ Data to High-Confidence Variant Calls: The Genome Analysis Toolkit Best Practices Pipeline. Current protocols in bioinformatics / editoral board, Andreas D. Baxevanis. [et al.], 2013, 11(1110):11.10.1-11.10.

5. 关于格致博雅

5.1 公司简介

北京格致博雅生物科技有限公司（简称“格致博雅”）是国内领先的高通量测序和生物信息学技术研发企业，自成立以来始终秉持着“让生命可知”的愿景，专注于动植物多组学测算服务，致力于为育种 4.0 提供智能化解决方案。格致博雅具备完整的基因检测技术链，拥有自动化的样本前处理平台、超高通量 DNBSEQ-T7 测序平台以及配备有大量自研数据处理流程的高性能计算中心，以“大数据+生物技术”为核心竞争力。格致博雅搭建有多基因分型检测、高通量测序和动植物多组学数据挖据的生物育种底层技术平台，提供基因组测序与分析、单细胞及多组学测序与分析和宠物基因检测三大技术服务。格致博雅现已获得国家高新技术企业、中关村高新技术企业、北京市“创新型”中小企业、ISO9001 质量体系认证等多项荣誉资质。

5.2 联系我们

北京市大兴区生物医药产业基地联东 U 谷 17 号楼

http://glbizzia.com/

E-Mail: support@glbizzia.com